Práctica 2. Estatística Descriptiva

Estatística

Grao en Enxeñaría Informática

Alejandro Saavedra Nieves e Ángel M. González Rueda

Índice

1. Táboas de frecuencias **2**

2. Representacións gráficas **5**

3. Medidas características **9**

4. Táboa resumo de funcións **12**

1. Táboas de frecuencias

Unha táboa de frecuencias está formada por varias columnas: as frecuencias absolutas, as relativas e as súas correspondentes frecuencias acumuladas, cando teñen sentido. Comezaremos por obter as frecuencias absolutas, para as que se emprega a función `table`. No caso das frecuencias relativas, é tan sinxelo como dividir as frecuencias absolutas previamente calculadas polo tamaño da mostra, que se pode obter facilmente coa función `length`.

Considera unha mostra de 20 observacións da variable $X :=$ "Satisfacción co servizo ao cliente" que introducimos en R do seguinte xeito:

```
> satisfaccion<-c("boa", "boa", "regular", "moi boa", "mala",
+                 "boa", "boa", "regular", "moi mala", "boa",
+                 "moi boa", "moi boa", "regular", "boa", "mala",
+                 "boa", "moi boa", "moi boa", "boa", "regular")
```

Esta variable definida deste xeito gárdase en R como unha variable de tipo carácter. Para convertila nunha tipo de factor (que é o tipo de variables que utiliza R para as variables cualitativas) e que lle permita comprender que hai determinadas categorías que se repiten na nosa mostra, faremos:

```
> satisfaccion<-as.factor(satisfaccion)
> levels(satisfaccion)

[1] "boa"     "mala"    "moi boa"    "moi mala"    "regular"
```

Por defecto, e como se ve na saída, R ordena as categorías alfabéticamente. Se queremos que aparezan nunha orde "lóxica", debemos permutalas segundo ese criterio:

```
> satisfaccion<-factor(satisfaccion, levels=levels(satisfaccion)[c(4,2,5,1,3)])
> levels(satisfaccion)

[1] "moi mala"    "mala"      "regular"    "boa"      "moi boa"
```

En primeiro lugar obteremos as frecuencias absoluta e relativa:

```
> Fabs<-table(satisfaccion)
> Fabs
satisfaccion
moi mala      mala   regular      boa    moi boa
       1         2         4         8            5
> Frel<-table(satisfaccion)/length(satisfaccion)
> Frel
```

```
satisfaccion
moi mala      mala   regular     boa    moi boa
    0.05      0.10      0.20      0.40         0.25
```

Para obter as **frecuencias acumuladas** (tanto absolutas como relativas) que neste caso ten sentido calcular por tratarse dunha variable cualitativa ordinal, utilízase a función `cumsum`:

```
> FabsAcum<-cumsum(Fabs)
> FabsAcum
 moi mala      mala   regular     boa    moi boa
        1         3         7        15           20
> FrelAcum<-cumsum(Frel)
> FrelAcum
moi mala      mala   regular     boa    moi boa
    0.05      0.15      0.35      0.75         1.00
```

Para ver a táboa de frecuencias completa, podemos "pegar por columnas" os vectores calculados previamente coa función `cbind`:

```
> Tabla<-cbind(Fabs,Frel,FabsAcum,FrelAcum)
> Tabla
          Fabs Frel FabsAcum FrelAcum
moi mala     1 0.05        1     0.05
mala         2 0.10        3     0.15
regular      4 0.20        7     0.35
boa          8 0.40       15     0.75
moi boa      5 0.25       20     1.00
```

Pode ser que esteamos interesados en redondear a un número específico de cifras decimais, para o que podemos usar a función `round`. Neste caso que ningún dos valores ten máis de dous decimais. Se tratamos de redondear a catro decimais, por poñer un exemplo, síguenos devolvendo o resultado con dous decimais, posto que o resto son cero.

```
> Tabla<-round(Tabla,4)
> Tabla
          Fabs Frel FabsAcum FrelAcum
moi mala     1 0.05        1     0.05
mala         2 0.10        3     0.15
regular      4 0.20        7     0.35
boa          8 0.40       15     0.75
moi boa      5 0.25       20     1.00
```

Agora vexamos un **exemplo con datos reais**. No ficheiro `quine`[1] do paquete MASS recóllense datos sobre o ausentismo escolar de 146 escolares de Nova Gales, Australia. Entre as variables recollidas están o sexo (`Sex`) e a idade (`Age`) medidos en grupos. Para construír as táboas de frecuencias correspondentes empregaremos o seguinte código (teña en conta que a variable `Age` está categorizada e é ordinal cualitativa, mentres que `Sex` é cualitativa nominal).

```
> library(MASS)
> attach(quine)
> ni<-table(Age)
> fi<-ni/length(Age)
> Ni<-cumsum(ni)
> Fi<-cumsum(fi)
> cbind(ni,fi,Ni,Fi)
    ni        fi  Ni        Fi
F0 27 0.1849315  27 0.1849315
F1 46 0.3150685  73 0.5000000
F2 40 0.2739726 113 0.7739726
F3 33 0.2260274 146 1.0000000

> ni<-table(Sex)
> fi<-ni/length(Sex)
> cbind(ni,fi)

ni        fi
F 80 0.5479452
M 66 0.4520548
```

A función `table` tamén permite construír **táboas de continxencia** nas que se representan os datos de dúas (ou máis) variables. Para o exemplo dos datos de absentismo escolar, podemos representar conxuntamente os individuos segundo o sexo e a idade, así como obter as distribucións marxinais coa función `margin.table` e completar a táboa coa función `addmargins` como segue:

```
> Tabla<-table(Age,Sex)
> margin.table(Tabla,1)
> margin.table(Tabla,2)
> addmargins(Tabla)
```

[1] A función `attach` permite acceder ás variables da base de datos directamente polo seu nome. É dicir, se non utilizamos `attach` para acceder aos datos da idade teriamos que usar o código `quine$Age`, mentres que unha vez executada a función `attach` podemos acceder a eles directamente con `Age`.

```
     Sex
Age   F  M Sum
F0   10 17  27
F1   32 14  46
F2   19 21  40
F3   19 14  33
Sum  80 66 146
```

Nota 1. O cálculo das distribucións marxinais tamén se pode programar a man (en lugar de usar as funcións `margin.table` e `addmargins`) usando as funcións `colSums`, `cbind`, `rowSums` e `rbind`.

2. Representacións gráficas

As representacións gráficas máis sinxelas para variables cualitativas ou cuantitativas discretas son o **gráfico de barras** e o **diagrama circular**, como vimos no Tema 1. Sobre os datos de exemplo iniciais sobre a variable $X :=$ "Satisfacción co servizo de atención ao cliente", poderiamos construír un gráfico de barras executando:

```
> barplot(table(satisfaccion),ylab="Proporción",col=4)
```

e para debuxar o diagrama de sectores faríamos:

```
> pie(table(satisfaccion),main="Satisfacción",
+     col=c("red","blue","green","orange","purple"))
```

Deste xeito obteriamos as representacións mostradas na Figura 1. Teña en conta que calquera das representacións anteriores podería obterse para unha táboa de frecuencias relativas simplemente dividindo polo tamaño da mostra, é dicir, `length(satisfacción)`.

No caso do **exemplo con datos reais**, representaremos tanto `Age` como `Sex` mediante gráficos de barras, no primeiro farémolo coas frecuencias absolutas e no segundo coas frecuencias relativas:

```
> barplot(table(Age),ylab="Frecuencias absolutas",col=3)
> barplot(table(Sex)/length(Sex),ylab="Frecuencias relativas",col=3)
```

Para variables cuantitativas continuas considere o exemplo dos datos do géiser de Old Faithful, dispoñibles no paquete `MASS`:

```
> library(MASS)
> attach(geyser)
> names(geyser)
[1] "waiting"  "duration"
```

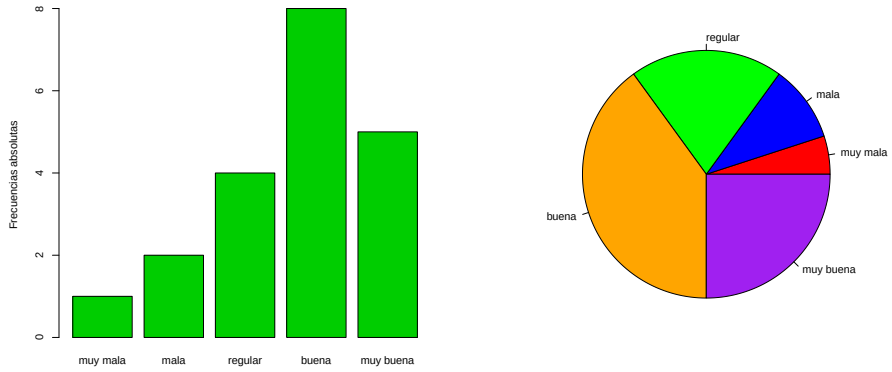


Figura 1: Diagramas de barras e sectores.

```
> length(duration)
```

```
[1] 299
```

Se debuxamos un gráfico de barras ou un gráfico circular para os datos de duración da erupción:

```
> barplot(duration)
> pie(duration)
```

demóstrase que ningunha delas é informativa cando se aplica a variables cuantitativas continuas (como xa sabiamos pola teoría estudada). Unha forma de aplicalos é categorizando, ou resumindo os valores da variable por intervalos, aínda que isto supón certa perda de información.

Unha das gráficas adecuadas para este tipo de datos é o histograma, que podemos debuxar en frecuencias absolutas ou relativas mediante a función `hist` co argumento `freq=FALSE` para as frecuencias relativas:

```
> hist(duration, main="Histograma del tiempo de erupción", xlab="tiempo")
> hist(duration, main="Histograma del tiempo de erupción", xlab="tiempo",
+      freq=F)
```

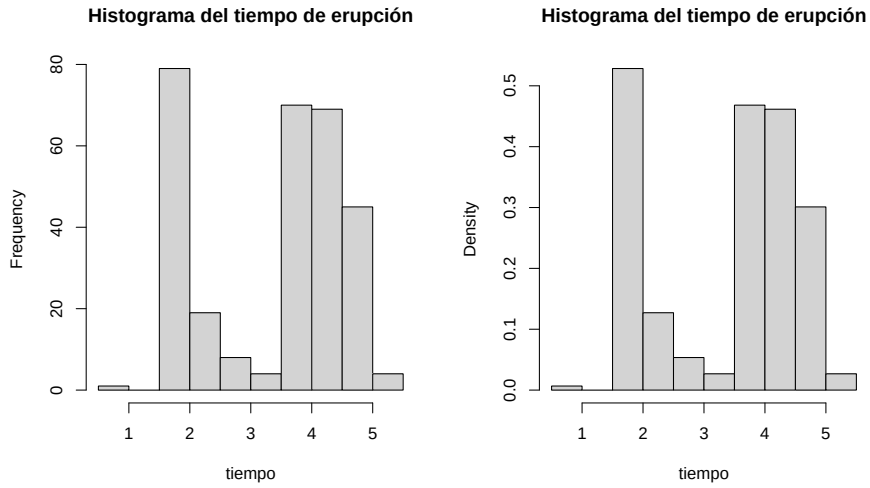


Figura 2: Histograma para a duración de erupción, con frecuencias absolutas e densidades.

O histograma é sensible ao número de intervalos que se están considerando. Na Figura 3 amosamos histogramas para diferentes números de intervalos, que están construídos en R modificando convenientemente o argumento `breaks`:

```
> par(mfrow=c(2,2))
> hist(duration,breaks=4,col="grey",main="Histograma con  5 intervalos")
> hist(duration,breaks=9,col="grey",main="Histograma con 10 intervalos")
> hist(duration,breaks=24,col="grey",main="Histograma con 25 intervalos")
> hist(duration,breaks=49,col="grey",main="Histograma con 50 intervalos")
```

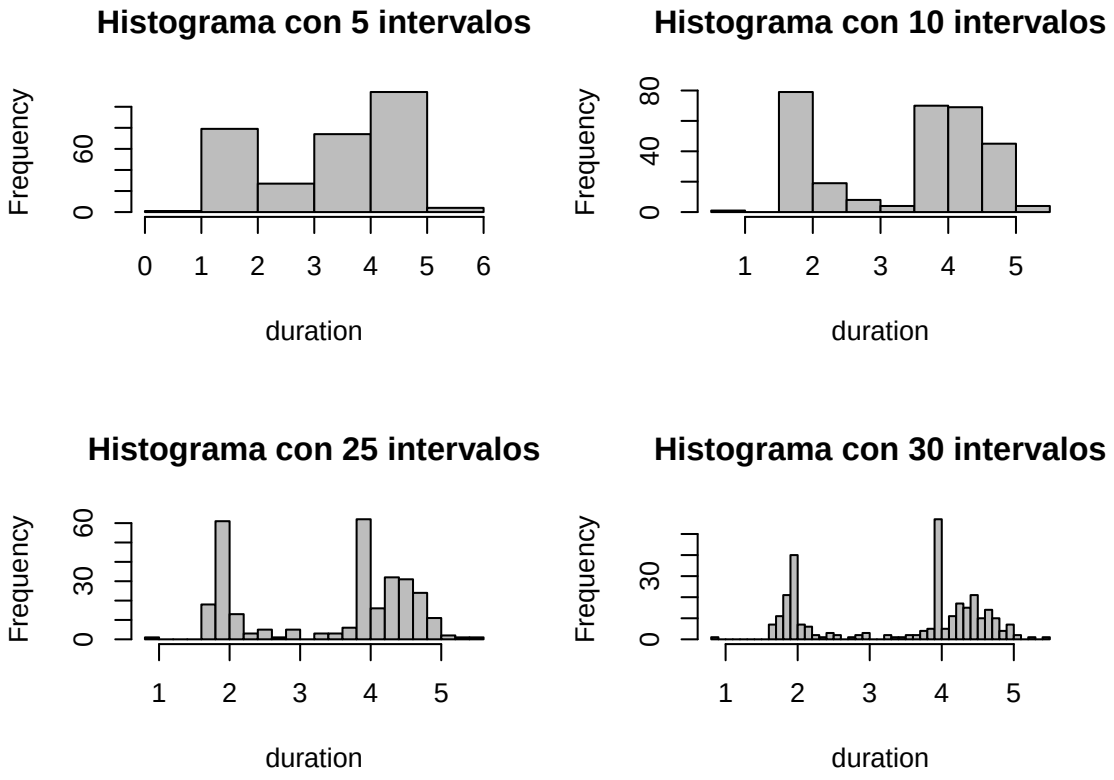


Figura 3: Histograma para a duración de erupción, con distintos números de intervalos.

Outra representación gráfica de variables cuantitativas continuas é o **diagrama de talo e follas**. Para obter tal diagrama con R usamos a función `stem`:

```
> stem(duration)
The decimal point is 1 digit(s) to the left of the |

8  | 3
10 |
12 |
14 |
16 | 223370023357778
18 | 000222233333355577788800223333333555557778
20 | 00000000000000000000000223578023578
22 | 0278
```

```
24 | 7807
26 | 05
28 | 373
30 | 00
32 | 583
34 | 523
36 | 00235
38 | 0277802377
40 | 00000000000000000000000000000000000000000000000000023780233355777
42 | 00222222355557778802333557788888
44 | 00222255555557777800000233888
46 | 00002225577778800033357778
48 | 0033782277788
50 | 30
52 | 7
54 | 5
```

3. Medidas características

A función `summary` dános información xeral sobre calquera variable. No caso das variables cuantitativas, o que se devolve é o valor do mínimo, o máximo, a media e os cuartiles. Para as variables cualitativas é máis sinxelo e devolve só un reconto por categorías, é dicir, as frecuencias absolutas (e polo tanto o mesmo que a función `table` que vimos antes).

Para calcular a **media** mostral empregamos a función `media` coa que tamén se pode obter **media recortada** mediante o argumento `trim`, que nos permite introducir unha fracción (de 0 a 0.5) indicando a porcentaxe dos datos máis alto e máis baixo que se elimina. Deste xeito, obtense unha media *robustificada* no sentido de que xa non é tan sensible á presenza de valores atípicos.

Non hai ningunha función en  que calcule a **varianza** da mostra. A función `var` devolve a mostra **cuasi-varianza**, polo que debemos transformar o resultado para obter a varianza:

$$S_c^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \Longrightarrow S^2 = \frac{n-1}{n}S_c^2.$$

Igual que a función `var`, a función `sd` proporciona a cuasi-desviación estándar da mostra. Se queremos calcular a desviación estándar da mostra podemos facelo utilizando a súa definición como raíz cadrada da varianza.

Outras funcións para obter medidas características que se viron no Tema 1 son:

- `median` para calcular a **mediana** da mostra.
- `min` para calcular o **mínimo** da mostra.
- `max` para calcular o **máximo** da mostra
- `diff(range)` para calcular o **rango da mostra**.
- `quantile` para calcular diferentes **cuantís** adaptando o argumento `probs`.
- `IQR` para calcular o **rango intercuartílico** da mostra.

Volvamos ao exemplo dos datos `geyser` da biblioteca `MASS` e á variable `duration` para calcularmos algunhas destas medidas:

```
> mean(duration) #media
[1] 3.460814
> median(duration) #mediana
[1] 4
> quantile(duration,probs=0.7) #cuantil 0.7
70%
4.266667
> quantile(duration, probs = c(0.25,0.5,0.75)) #cuartiles
     25%      50%      75%
2.000000 4.000000 4.383333
> var(duration) #cuasi-varianza
[1] 1.317683
> diff(range(duration)) #rango
[1] 4.616667
```

Tamén nos pode interesar a simetría e a forma da variable. Para obter os coeficientes de asimetría e curtose, debemos cargar o paquete `moments`. As funcións a utilizar son:

- `skewness` para calcular o **coeficiente de asimetría**.

- `kurtosis` para calcular o **coeficiente de curtose**.

Como tamén vimos, unha forma de resumir a información das medidas características é representar un **diagrama de caixas** ou Box-Plot. Obteríamos esta representación en R do seguinte xeito:

```
> boxplot(duration)
```

O diagrama de caixas ou Box-Plot resume nun só gráfico algunhas das medidas de centralización e dispersión máis utilizadas en estatística. A barra negra central indica o valor da mediana, mentres que os extremos das caixas son o primeiro cuartil, Q_1, (inferior) e o terceiro cuartil, Q_3 (superior). Así, a altura da caixa é o intervalo intercuantílico $Q_3 - Q_1$. Se a variable é simétrica, a mediana debe situarse nun punto equidistante de ambos os cuartiles e coincidirá coa media. Os extremos das barras no Box-Plot representan os límites superior e inferior. As observacións que quedan fóra destes límites son valores atípicos. Vexa a Figura 4.

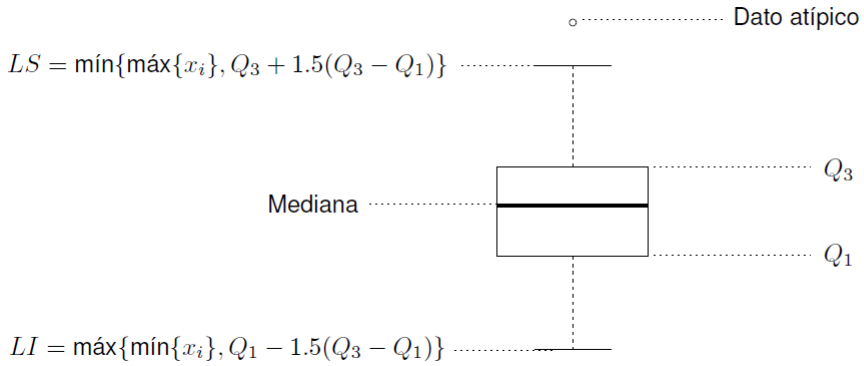


Figura 4: Diagrama de caixas.

Agora vexamos un novo **exemplo con datos de calidade do aire.** O conxunto de datos `airquality` contén información sobre a calidade do aire. Entre outras variables, recóllese a velocidade do vento rexistrada (`Wind`) en millas por hora, que é unha variable cuantitativa continua. Para representar graficamente esta variable necesitamos:

```
> attach(airquality)
> names(airquality)
[1] "Ozone"   "Solar.R" "Wind"    "Temp"    "Month"   "Day"

> hist(Wind, col="blue", main="Histograma", xlab="Velocidad del viento")
> boxplot(Wind,col="purple",main="Diagrama de caja", xlab="Velocidad
+         del viento")
```

Como xa vimos no exemplo dos datos `geyser`, o número de intervalos do histograma pódese modificar co argumento `breaks`.

4. Táboa resumo de funcións

Funcións principais	
Tamaño da mostra	`length`
Táboas de frecuencias	`table`
Marxinais	`addmargins`
Diagrama de barras	`barplot`
Diagrama de sectores	`pie`
Histograma	`hist`
Diagrama de talo e follas	`stem`
Diagrama de caixa	`boxplot`
Media	`mean`
Cuasi-varianza	`var`
Mediana	`median`
Cuantil	`quantile`
Rango intercuartílico	`IQR`
Rango	`diff` e `range`
Asimetría	`skewness`
Curtose	`kurtosis`

Outras funcións	
Instalar paquete	`install.packages`
Cargar paquete	`library`
Sumas acumuladas	`cumsum`
Redondeo	`round`
Resumen de medidas	`summary`
Adxuntar datos	`attach`
Nombres dun obxecto	`names`

ANEXO: Exercicio 6.

Recupera o ficheiro .csv que se utilizou no exercicio 6 da Práctica 1. Lembra que estes datos foron obtidos da páxina web do Instituto Galego de Estatística (ver guión da práctica 1) e tamén están dispoñibles no Campus Virtual da materia.

Importe os datos a  e comprobe que todo funcionou correctamente usando o comando `fix`.

Agora defina unha nova base de datos que conteña só os datos correspondentes á provincia da Coruña para o ano 2019.

1. Compara graficamente as idades dos homes e das mulleres.
2. Obter medidas características das idades de homes e mulleres.
3. Hai algún valor atípico?

Solución:

```
# Importamos os datos (recorda cambiar o directio
# de traballo a onde teñas gardado o arquivo)
datosIGE<-read.csv("DatosIGE.csv",sep=",",header=TRUE)
fix(datosIGE)
names(datosIGE)

# Escollemos os datos correspondentes a provincia de Lugo e ao ano 2019
datosnew <- datosIGE[datosIGE$CodEspazo==27 & datosIGE$CodTempo==2019,]

# Creamos unha base de datos para homes e outra para mulleres
datosHomes<-datosnew[datosnew$Sexo=="Homes",]
datosMulleres<-datosnew[datosnew$Sexo=="Mulleres",]

# Definimos a variable Idade en homes de 0 a 84 años
IdadeHomes<-rep(0,datosHomes$DatoN[1])
for (i in 2:85) {
    IdadeHomes<-c(IdadeHomes,rep(i-1,datosHomes$DatoN[i]))
}

# Definimos a variable Idade en mulleres de 0 a 84 años
IdadeMulleres<-rep(0,datosMulleres$DatoN[1])
for (i in 2:85) {
```

```
    IdadeMulleres<-c(IdadeMulleres,rep(i-1,datosMulleres$DatoN[i]))
}

# Representamos os histogramas para ambos os grupos
windows()
par(mfrow=c(1,2))
hist(IdadeHomes,freq=F,ylim=c(0,0.02),main="Homes")
hist(IdadeMulleres,freq=F,ylim=c(0,0.02),main="Mulleres")

# Representamos os diagramas de caixa para ambos os grupos
par(mfrow=c(1,2))
boxplot(IdadeHomes,main="Homes")
boxplot(IdadeMulleres,main="Mulleres")

# Calculamos as medidas características da Idade en ambos grupos
summary(IdadeHomes)
summary(IdadeMulleres)
```